



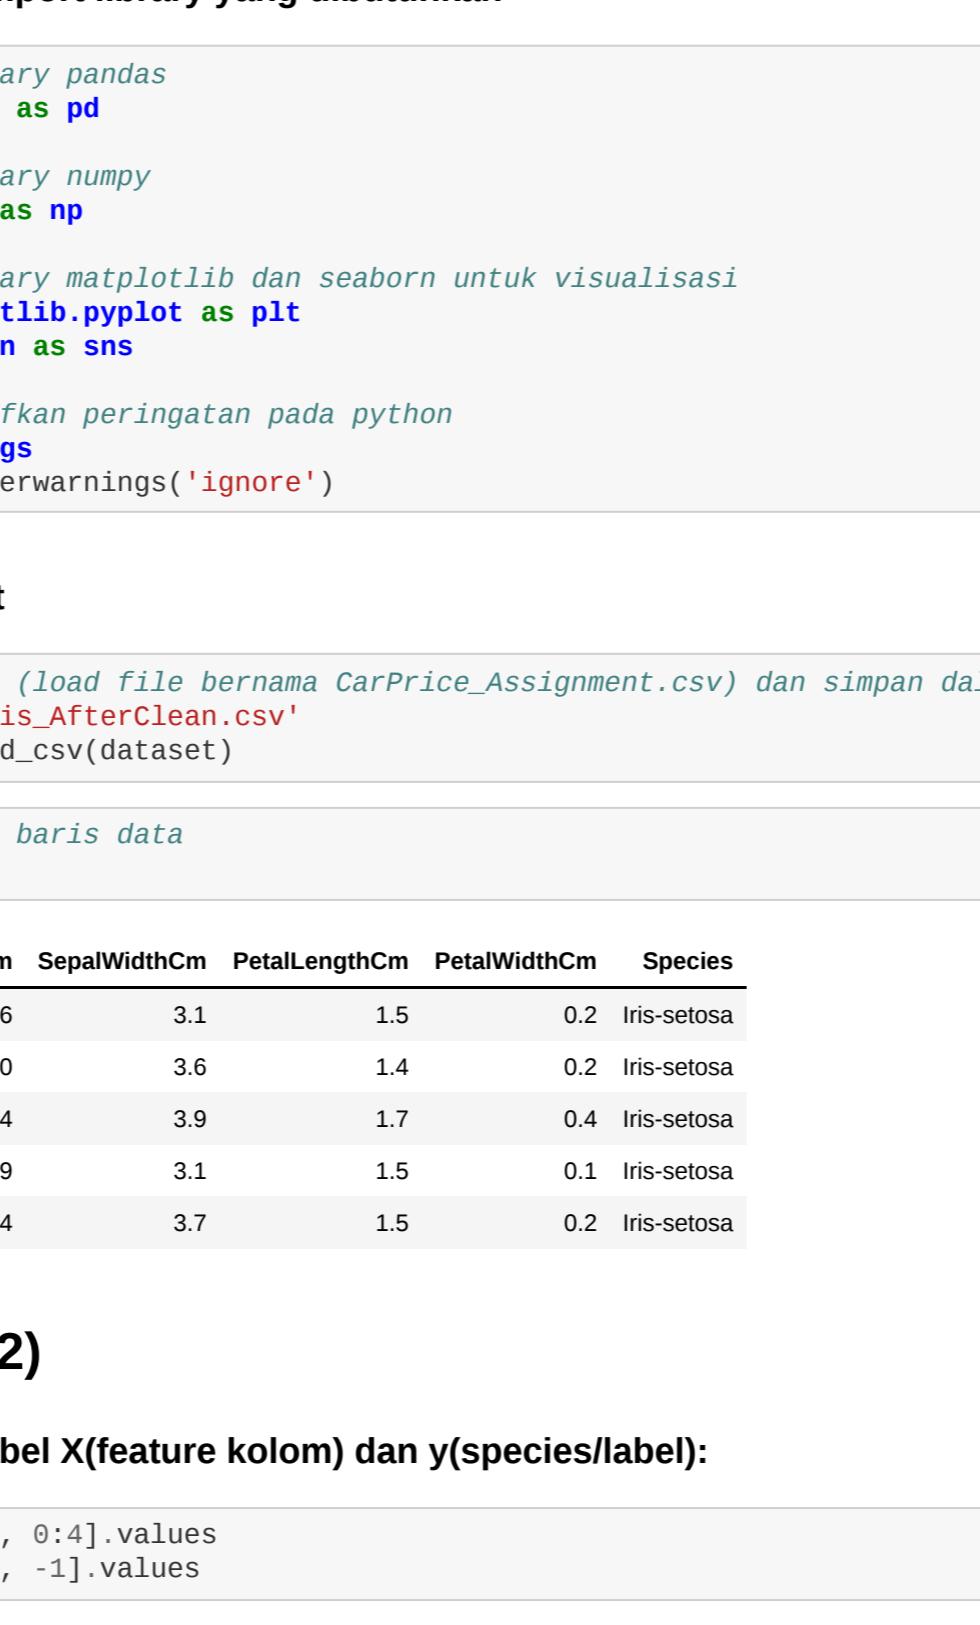
Hands-On

Hands-On ini digunakan pada kegiatan Microcredential Associate Data Scientist 2021

Tugas Mandiri Pertemuan 12

Pertemuan 12 (duabelas) pada Microcredential Associate Data Scientist 2021 menyampaikan materi mengenai Membangun Model 3 (Regresi dengan Tree). Silakan Anda kerjakan Latihan 1 s/d 10. Output yang anda lihat merupakan panduan yang dapat anda ikuti dalam penulisan code.)

About Iris dataset



The iris dataset contains the following data (Before Cleansing)

- 50 samples of 3 different species of iris (150 samples total)
- Measurements: sepal length, sepal width, petal length, petal width
- The format for the data: (sepal length, sepal width, petal length, petal width)

The variables are:

- `sepal_length`: Sepal length, in centimeters, used as input.
- `sepal_width`: Sepal width, in centimeters, used as input.
- `petal_length`: Petal length, in centimeters, used as input.
- `petal_width`: Petal width, in centimeters, used as input.
- `class`: Iris Setosa, Versicolor, or Virginica, used as the target.

Latihan (1)

Melakukan import library yang dibutuhkan

```
In [2]: # import library pandas
import pandas as pd

# Import library numpy
import numpy as np

# Import library matplotlib dan seaborn untuk visualisasi
import matplotlib.pyplot as plt
import seaborn as sns

# me-non aktifkan peringatan pada python
import warnings
warnings.filterwarnings('ignore')
```

Load Dataset

```
In [3]: # download file (load file bernama CarPrice_Amountment.csv) dan simpan dalam dataframe
dataset = 'Iris_AfterClean.csv'
iris = pd.read_csv(dataset)
```

```
In [4]: # tampilkan 5 baris data
iris.head()
```

```
Out[4]:
```

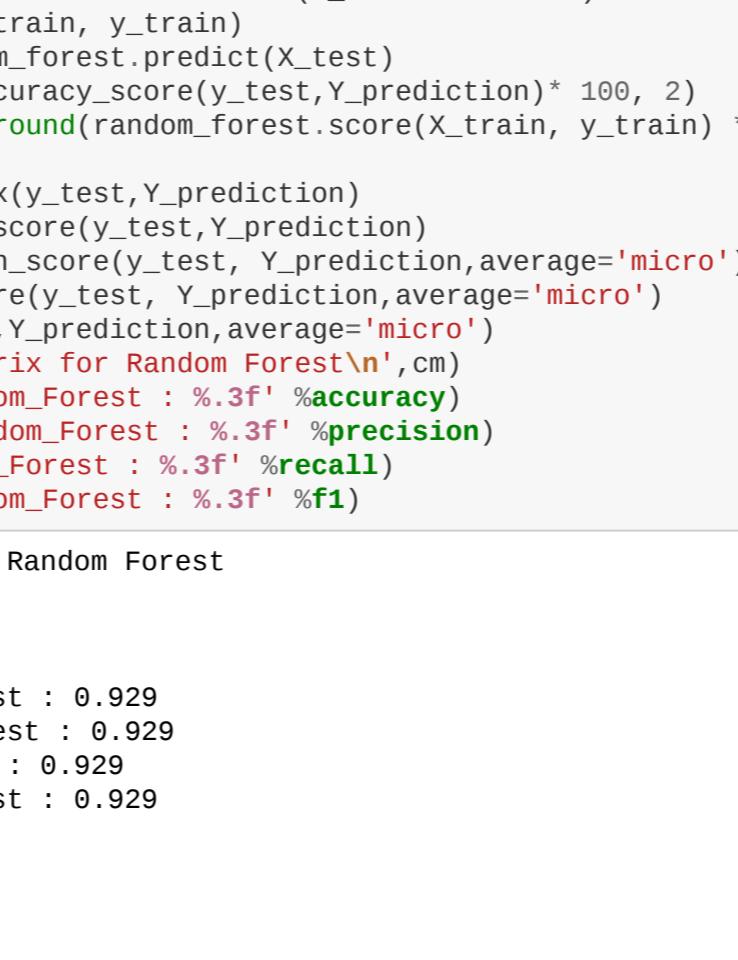
	SepalLengthCm	SepalWidthCm	PetalLengthCm	PetalWidthCm	Species
0	4.6	3.1	1.5	0.2	Iris-setosa
1	5.0	3.6	1.4	0.2	Iris-setosa
2	5.4	3.9	1.7	0.4	Iris-setosa
3	4.9	3.1	1.5	0.1	Iris-setosa
4	5.4	3.7	1.5	0.2	Iris-setosa

Latihan (2)

definisi variabel X(feature kolom) dan y(species/label):

```
In [5]: x=iris.iloc[:, 0:4].values
y=iris.iloc[:, -1].values
```

Label encoding



Seperi yang kita lihat, label bersifat kategoris. KNeighborsClassifier tidak menerima label string. Kita perlu menggunakan LabelEncoder untuk mengubahnya menjadi angka. Iris-setosa sesuai dengan 0, Iris-versicolor sesuai dengan 1 dan Iris-virginica sesuai dengan 2.

Latihan (3)

transform label data species dengan menggunakan library LabelEncoder

```
In [6]: from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
y = le.fit_transform(y)
```

3. Building Machine Learning Models

Latihan (4)

import library dalam kebutuhan membangun model

```
In [7]: #Metrics
from sklearn.metrics import make_scorer, accuracy_score, precision_score
from sklearn.metrics import classification_report

# Import Library Confusion Matrix
from sklearn.metrics import confusion_matrix

from sklearn.metrics import accuracy_score, precision_score, recall_score, f1_score

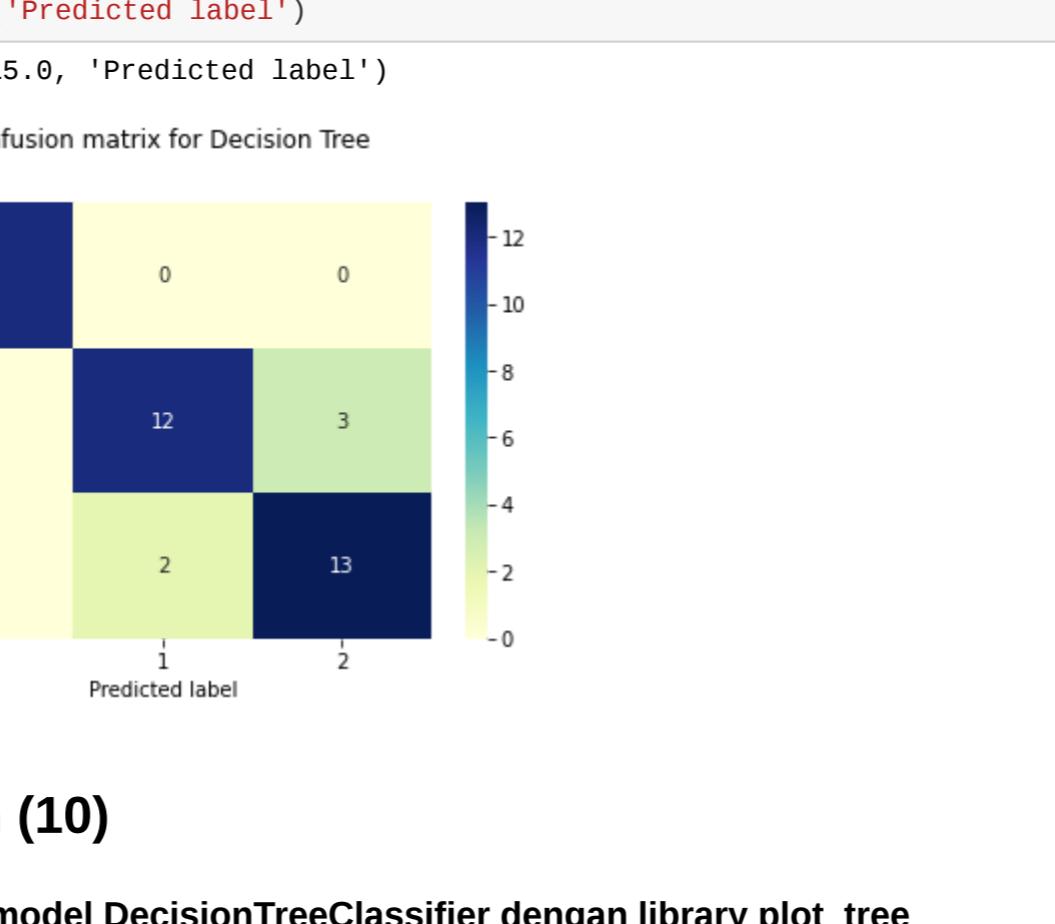
#Model Select
from sklearn.model_selection import KFold, train_test_split, cross_val_score

# Import Library Random Forest Classifier
from sklearn.ensemble import RandomForestClassifier

# From sklearn import linear_model
from sklearn import linear_model
```

Splitting The Data into Training And Testing Dataset

Train/test split adalah salah satu metode yang dapat digunakan untuk mengevaluasi performa model machine learning. Metode evaluasi model ini membagi dataset menjadi dua bagian yakni bagian yang digunakan untuk training data dan untuk testing data dengan proporsi tertentu. Train data digunakan untuk fit model machine learning, sedangkan test data digunakan untuk mengevaluasi hasil fit model tersebut.



Latihan (5)

split data train dan test dengan function `train_test_split()` dengan `train_size=0.7, test_size=0.3 dan random_state=0`

```
In [8]: #Train and Test split
X_train, X_test, y_train, y_test = train_test_split(X,y,test_size=0.3,random_state=0)
```

Sekarang kita akan melihat beberapa model Machine Learning dan membandingkan hasilnya. Perhatikan bahwa karena set data tidak memberikan label untuk set pengujian, kita perlu menggunakan prediksi pada set pelatihan untuk membandingkan algoritme sama-sama lain.

3.1 Random Forest:

Random forest, seperti namanya, terdiri dari sejumlah besar pohon keputusan individu yang beroperasi sebagai ansambel. Setiap pohon individu di hutan acak mengeluarkan prediksi kelas dan kelas dengan suara terbanyak menjadi prediksi model kami.

Sejumlah besar model (pohon) yang relatif tidak berkorelasi yang beroperasi sebagai komite akan mengungguli model konstituen individu mana pun.

Latihan (6)

Bangun model Random Forest dan akurasi nya

```
In [9]: random_forest = RandomForestClassifier(n_estimators=100)
random_forest.fit(X_train, y_train)
Y_prediction = random_forest.predict(X_test)
accuracy_rf=round(accuracy_score(y_test,Y_prediction)* 100, 2)
acc_random_forest = round(random_forest.score(X_train, y_train) * 100, 2)

cm = confusion_matrix(y_test,Y_prediction)
accuracy = accuracy_score(y_test,Y_prediction)
precision = precision_score(y_test, Y_prediction, average='micro')
recall = recall_score(y_test, Y_prediction, average='micro')
f1 = f1_score(y_test, Y_prediction, average='micro')
print('Confusion matrix for Random Forest\n',cm)
print('accuracy_random_Forest : %.3f' %accuracy)
print('precision_random_Forest : %.3f' %precision)
print('recall_random_Forest : %.3f' %recall)
print('f1-score_random_Forest : %.3f' %f1)

Confusion matrix for Random Forest
[[12  0  0]
 [ 0 14  1]
 [ 0  2 13]]
accuracy_random_Forest : 0.929
precision_random_Forest : 0.929
recall_random_Forest : 0.929
f1-score_random_Forest : 0.929
```

Latihan (7)

Visualisasikan Nilai Confusion Matrix dari Model Random Forest

```
In [10]: from sklearn import metrics
cm = metrics.confusion_matrix(y_test, Y_prediction)
cm, annot=True, cmap="YlGnBu", fmt='g')
plt.title('Confusion matrix for Random Forest', y=1.1)
plt.xlabel('Actual label')
plt.ylabel('Predicted label')
```

```
Out[10]: Text(0.5, 15.0, 'Predicted label')
```

Confusion matrix for Random Forest

3.6 Decision Tree:

decision tree adalah struktur seperti diagram alir di mana setiap simpul internal mewakili pengujian pada fitur (misalkan apakah flip koin muncul kepala atau ekor), setiap simpul daun mewakili kelas (keputusan diambil setelah menghitung semua fitur) dan cabang mewakili konjungsi fitur yang mengarah ke label kelas tersebut. Jalan dari akar ke daun mewakili aturan klasifikasi.

Latihan (8)

Bangun model DecisionTreeClassifier dan akurasi nya

```
In [11]: from sklearn.tree import DecisionTreeClassifier
decision_tree = DecisionTreeClassifier()
decision_tree.fit(X_train, y_train)
Y_pred= decision_tree.predict(X_test)
accuracy_dt=round(accuracy_score(y_test,Y_pred)* 100, 2)
acc_decision_tree = round(decision_tree.score(X_train, y_train) * 100, 2)

cm = confusion_matrix(y_test,Y_pred)
accuracy = accuracy_score(y_test,Y_pred)
precision = precision_score(y_test, Y_pred, average='micro')
recall = recall_score(y_test, Y_pred, average='micro')
f1 = f1_score(y_test, Y_pred, average='micro')
print('Confusion matrix for DecisionTree\n',cm)
print('accuracy_DcisionTree : %.3f' %accuracy)
print('precision_DcisionTree : %.3f' %precision)
print('recall_DcisionTree : %.3f' %recall)
print('f1-score_DcisionTree : %.3f' %f1)

Confusion matrix for DecisionTree
[[12  0  0]
 [ 0 12  3]
 [ 0  2 13]]
accuracy_DcisionTree : 0.881
precision_DcisionTree : 0.881
recall_DcisionTree : 0.881
f1-score_DcisionTree : 0.881
```

Latihan (9)

Visualisasikan Nilai Confusion Matrix dari Model Decision Tree

```
In [12]: from sklearn import metrics
cm = metrics.confusion_matrix(y_test, Y_pred)
cm, annot=True, cmap="YlGnBu", fmt='g')
plt.title('Confusion matrix for Decision Tree', y=1.1)
plt.xlabel('Actual label')
plt.ylabel('Predicted label')
```

```
Out[12]: Text(0.5, 15.0, 'Predicted label')
```

Confusion matrix for Decision Tree

Latihan (10)

Plot hasil model DecisionTreeClassifier dengan library `plot_tree`

```
In [15]: from sklearn.tree import plot_tree
plt.figure(figsize=(15,10))
plot_tree(decision_tree.fit(X_train, y_train) ,filled=True)
plt.show()
```



```
In [ ]:
```